

BÁO CÁO ĐỌC HIỂU PAPER

HMoE

Heterogeneous Mixture of Experts for Language Modeling

Phân tích phương pháp, công thức và kết quả thực nghiệm

Họ và tên:

MSSV:

Lớp:

Môn học:

Giảng viên:

Ngày nộp:

Mục lục

1	Giới thiệu	3
2	Mixture of Experts truyền thống	4
2.1	Mixture of Experts	4
2.2	Router trong MoE	4
2.3	Top-K Routing	5
2.4	Top-P Routing	5
3	Vấn đề của Homogeneous MoE	6
4	Phương pháp đề xuất: Heterogeneous Mixture of Experts	6
4.1	Ý tưởng chính	6
4.2	Cấu trúc expert	7
4.3	Vấn đề khi dùng HMoE trực tiếp	8
4.4	Load Balancing Loss truyền thống	8
4.5	P-Penalty Loss	9
4.6	Router Entropy Loss	10
5	Thiết kế kích thước expert	11
5.1	Geometric Strategy	11
5.2	Arithmetic Strategy	11
5.3	Hybrid Strategy	11
6	Thiết lập thực nghiệm	12
7	Kết quả thực nghiệm	13
7.1	IsoFLOP Analysis	13
7.2	Kết quả trên benchmark	14
8	Ablation Study	14

8.1	Ảnh hưởng của P-Penalty Loss	14
8.2	Ảnh hưởng của mức độ heterogeneity	15
9	Phân tích chuyên sâu	15
9.1	Chuyên môn hóa của expert	15
9.2	Token khó và token dễ	16
10	Hiệu quả tính toán	16
11	Đánh giá cá nhân	17
12	Kết luận	17
	Tài liệu tham khảo	18

1. Giới thiệu

Trong những năm gần đây, các mô hình ngôn ngữ lớn đã đạt được nhiều thành tựu nổi bật trong xử lý ngôn ngữ tự nhiên. Tuy nhiên, khi quy mô mô hình tăng lên các tập dữ liệu hiện tại càng đa dạng phức tạp, khiến việc học từ dữ liệu khó khăn làm hạn chế khả năng của mô hình đồng thời chi phí tính toán và yêu cầu bộ nhớ cũng tăng rất mạnh. Một trong những hướng tiếp cận quan trọng để giải quyết vấn đề này là kiến trúc **Mixture of Experts**.

Mixture of Experts(MoE), cho phép mô hình có số lượng tham số rất lớn nhưng chỉ kích hoạt một phần tham số cho mỗi token đầu vào tức là chia thành nhiều expert và dùng cơ chế router/gate chọn và kích hoạt expert phù hợp cho từng đầu vào. Nhờ vậy, mô hình có thể tăng năng lực biểu diễn mà không làm chi phí tính toán tăng tuyến tính như mô hình dense đặc biệt hữu ích cho mô hình lớn, dữ liệu đa dạng và các tác vụ phức tạp.

Tuy nhiên vấn đề đặt ra ở mô hình MoE truyền thống là khi sử dụng các expert đồng nhất tức là có cùng kích thước và năng lực biểu diễn khi đó:

- Các expert giống nhau nên khó chuyên môn hóa, nhiều expert có thể học đặc trưng tương tự nhau.
- Việc phân bổ tham số chưa hiệu quả, token dễ/ token khó đều được expert có năng lực như nhau xử lý.
- Có thể xảy ra mất cân bằng tải hoặc representation collapse tức là nhiều token bị dồn vào một expert

Bài báo *HMoE: Heterogeneous Mixture of Experts for Language Modeling* đề xuất một biến thể mới của MoE, gọi là **Heterogeneous Mixture of Experts** hay **HMoE**. HMoE giữ nguyên cơ chế tổng quát của MoE gồm router và các expert, nhưng thay đổi thiết kế expert bằng cách cho các expert có kích thước khác nhau. Các expert nhỏ phù hợp với những token đơn giản, trong khi các expert lớn có thể xử lý các token phức tạp hơn. Cách thiết kế này giúp mô hình tận dụng tài nguyên tính toán linh hoạt hơn so với MoE đồng nhất.

2. Mixture of Experts truyền thống

2.1. Mixture of Experts

Mixture of Experts là một kiến trúc trong đó mô hình gồm nhiều mạng con gọi là **experts**. Một thành phần khác gọi là **router** / **gating function** sẽ quyết định expert nào được kích hoạt cho từng token đầu vào.

Trong Transformer truyền thống, mỗi block thường có tầng Feed-Forward Network, mỗi tầng này được áp dụng độc lập lên mỗi token nhưng tất cả token lại dùng chung một bộ trọng số FFN. Mà với MoE, tầng FFN này được thay bằng một tập nhiều expert, mỗi expert có thể được xem là một FFN riêng biệt. Vậy nên MoE thường được dùng để thay tầng FFN.

MoE giúp mô hình mở rộng số lượng tham số tổng thể, nhưng chỉ sử dụng một số expert nhất định tại mỗi bước tính toán.

Công thức tổng quát của MoE:

$$\text{MoE}(x) = \sum_{i=1}^N g_i(x) e_i(x) \quad (1)$$

Trong đó:

- x là vector biểu diễn đầu vào.
- N là số lượng expert.
- $e_i(x)$ là đầu ra của expert thứ i .
- $g_i(x)$ là trọng số router gán cho expert thứ i .

Nếu $g_i(x) = 0$, expert thứ i không được kích hoạt cho token đó.

2.2. Router trong MoE

Router, hay còn gọi là Gating Function, là thành phần quyết định token hoặc đầu vào x sẽ được gửi đến expert nào. Với K expert, router tạo ra một vector xác suất:

$$\boldsymbol{\pi}(x) = [\pi_1(x), \pi_2(x), \dots, \pi_K(x)] \quad (2)$$

Trong đó, $\pi_i(x)$ là xác suất hoặc trọng số router gán cho expert thứ i . Một cách phổ biến để tính xác suất routing là dùng hàm softmax:

$$\pi_i(x) = \frac{\exp(a_i(x))}{\sum_{j=1}^K \exp(a_j(x))} = \frac{\exp(W_i x)}{\sum_{j=1}^K \exp(W_j x)}. \quad (3)$$

Với:

- $a_i(x)$ là logit, tức điểm số thô mà router tính cho expert thứ i ;
- W_i là tham số học được của router tương ứng với expert thứ i ;
- $\pi_i(x)$ là xác suất đầu vào x được gán cho expert thứ i .

Vector xác suất do router tạo ra thỏa mãn:

$$\pi_i(x) \geq 0, \quad \forall i, \quad (4)$$

$$\sum_{i=1}^K \pi_i(x) = 1. \quad (5)$$

2.3. Top-K Routing

Trong **Top-K Routing**, router luôn chọn đúng K expert có xác suất cao nhất.

$$g_i(x) = \begin{cases} \frac{P_i}{\sum_{j \in \text{Top-K}(P)} P_j}, & i \in \text{Top-K}(P) \\ 0, & i \notin \text{Top-K}(P) \end{cases} \quad (6)$$

Ưu điểm của Top-K là đơn giản và ổn định. Tuy nhiên, hạn chế của nó là số expert được kích hoạt luôn cố định, không phụ thuộc vào độ khó của token.

2.4. Top-P Routing

Trong **Top-P Routing**, router không chọn số expert cố định. Thay vào đó, router chọn số expert nhỏ nhất sao cho tổng xác suất vượt qua một ngưỡng p .

Giả sử $\tilde{P}$ là phân phối xác suất đã được sắp xếp giảm dần. Khi đó:

$$t = \arg \min_{k \in \{1, \dots, N\}} \sum_{j=1}^k \tilde{P}_j \geq p \quad (7)$$

Tập expert được chọn là:

$$\text{Top-P}(P) = \{\text{Index}(1), \dots, \text{Index}(t)\} \quad (8)$$

Sau đó trọng số routing được chuẩn hóa như sau:

$$g_i(x) = \begin{cases} \frac{P_i}{\sum_{j \in \text{Top-P}(P)} P_j}, & i \in \text{Top-P}(P) \\ 0, & i \notin \text{Top-P}(P) \end{cases} \quad (9)$$

Top-P Routing linh hoạt hơn Top-K vì token dễ có thể chỉ cần ít expert, còn token khó có thể kích hoạt nhiều expert hơn.

3. Vấn đề của Homogeneous MoE

Phần lớn các mô hình MoE trước đây sử dụng **homogeneous experts**, tức là tất cả expert có cùng kiến trúc và cùng kích thước. Thiết kế này đơn giản, dễ triển khai, nhưng có một số hạn chế quan trọng.

Thứ nhất, vì các expert có cùng năng lực biểu diễn, chúng có thể học các đặc trưng tương tự nhau. Điều này làm giảm khả năng chuyên môn hóa của từng expert.

Thứ hai, homogeneous MoE không phân biệt rõ token dễ và token khó. Một token đơn giản vẫn có thể được đưa vào expert lớn ngang với token khó, gây lãng phí tài nguyên. Ngược lại, token phức tạp có thể không nhận đủ năng lực biểu diễn cần thiết.

Thứ ba, mô hình có thể gặp hiện tượng **load imbalance**, tức là một số expert được sử dụng quá nhiều trong khi các expert khác ít được kích hoạt. Khi đó, hiệu quả sử dụng tham số giảm và quá trình huấn luyện cũng trở nên kém ổn định.


4. Phương pháp đề xuất: Heterogeneous Mixture of Experts

4.1. Ý tưởng chính

Bài báo đề xuất **Heterogeneous Mixture of Experts**, viết tắt là **HMoE**. Khác với MoE truyền thống, HMoE sử dụng các expert có kích thước khác nhau.

Trong HMoE:

- expert nhỏ có ít tham số hơn, phù hợp với token đơn giản;
- expert lớn có nhiều tham số hơn, phù hợp với token phức tạp;
- router học cách phân phối token đến expert phù hợp.



Hình 1: So sánh giữa homogeneous MoE và HMoe. Trong homogeneous MoE, các expert có cùng kích thước. Trong HMoe, các expert có kích thước khác nhau.

4.2. Cấu trúc expert

Paper sử dụng thiết kế FFN theo kiểu LLaMA cho mỗi expert. Công thức của expert thứ i là:

$$e_i(x) = W_{o,i} (\text{SiLU}(W_{g,i}x) \odot (W_{p,i}x)) \quad (10)$$

Trong đó:

$$\text{SiLU}(z) = z \cdot \sigma(z) \quad (11)$$

và

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (12)$$

SiLU giống như một bộ lọc mềm, giúp mô hình điều chỉnh lượng thông tin đi qua FFN. Các ma trận tham số của expert thứ i gồm:

$$W_{g,i} \in \mathbb{R}^{h_{\text{input}} \times h_{\text{ffn},i}} \quad (13)$$

$$W_{p,i} \in \mathbb{R}^{h_{\text{input}} \times h_{\text{ffn},i}} \quad (14)$$

$$W_{o,i} \in \mathbb{R}^{h_{\text{ffn},i} \times h_{\text{input}}} \quad (15)$$

Điểm quan trọng là $h_{\text{ffn},i}$ thay đổi theo từng expert. Đây chính là yếu tố tạo nên HMoE.


4.3. Vấn đề khi dùng HMoE trực tiếp

Nếu chỉ thay expert đồng nhất bằng expert khác kích thước, mô hình chưa chắc hoạt động tốt. Paper chỉ ra rằng router có xu hướng chọn expert lớn nhiều hơn vì expert lớn có năng lực biểu diễn mạnh hơn.

Điều này tạo ra một vòng lặp không tốt:

1. expert lớn được chọn nhiều hơn;
2. expert lớn được huấn luyện nhiều hơn;
3. expert lớn càng trở nên mạnh hơn;
4. router lại càng chọn expert lớn nhiều hơn.

Hiện tượng này khiến expert nhỏ bị bỏ qua và làm giảm lợi ích của HMoE. Vì vậy, HMoE cần một cơ chế huấn luyện để khuyến khích mô hình sử dụng expert nhỏ khi có thể, thay vì luôn ưu tiên expert lớn.



Hình 2: Kết quả thực nghiệm của phiên bản HMoE trực quan. Biểu đồ bên trái so sánh hiệu năng giữa HMoE trực quan và MoE đồng nhất. Biểu đồ bên phải thể hiện tỷ lệ kích hoạt của các expert trong HMoE.

4.4. Load Balancing Loss truyền thống

Trong MoE truyền thống, một hàm loss phụ thường được dùng để cân bằng tải giữa các expert. Công thức có dạng:

$$L_{\text{lb}} = N \sum_{i=1}^N T_i \cdot \hat{P}_i \quad (16)$$

Trong đó:

$$T_i = \frac{1}{T} \sum_{t=1}^T \mathbf{1}\{e_i \in E^t\} \quad (17)$$

$$\hat{P}_i = \frac{1}{T} \sum_{t=1}^T P_{i,t} \quad (18)$$

Ý nghĩa:

- T_i là tỷ lệ token được gán cho expert i .
- $P_{i,t}$ là xác suất router gán cho expert i khi xử lý token t .
- $\hat{P}_i$ là xác suất routing trung bình của expert i .
- T là tổng số token.
- E^t là tập expert được kích hoạt cho token thứ t .

Load Balancing Loss phù hợp với homogeneous MoE vì mọi expert có cùng kích thước. Tuy nhiên, với HMoE, các expert có kích thước khác nhau, nên cân bằng số lần dùng expert là chưa đủ.

4.5. P-Penalty Loss

Để phù hợp với HMoE, paper đề xuất **P-Penalty Loss**. Ý tưởng là nếu mô hình dùng nhiều expert lớn, loss sẽ tăng lên. Nhờ đó, mô hình được khuyến khích dùng expert nhỏ nhiều hơn khi có thể.

Công thức P-Penalty Loss là:

$$L_{\text{P-Penalty}} = N \sum_{i=1}^N M_i \cdot \hat{P}_i \quad (19)$$

Trong đó:

$$M_i = \frac{1}{T} \sum_{t=1}^T \mathbf{1}\{e_i \in E^t\} \times h_{\text{ffn},i} \quad (20)$$

Ý nghĩa:

- $h_{\text{ffn},i}$ là kích thước của expert i .
- $\hat{P}_i$ là xác suất routing trung bình của expert i .
- T là tổng số token.
- N là tổng số expert.
- E^t là tập expert được kích hoạt cho token thứ t .

Ở đây, $h_{\text{ffn},i}$ biểu diễn kích thước hidden dimension của expert thứ i . Nếu expert lớn được kích hoạt nhiều, M_i sẽ lớn hơn, làm tăng penalty tức là khuyến khích mô hình token đơn giản thì dùng expert nhỏ, token phức tạp dùng expert lớn nếu cần thật sự. Điều này giúp các expert đều được huấn luyện đồng đều.

4.6. Router Entropy Loss

Với Top-P Routing, số expert được kích hoạt là động có thể tăng dần trong quá trình huấn luyện. Để hạn chế điều này lấy ý tưởng từ hàm Entropy trong xác suất nhằm đo mức độ phân tán hoặc không chắc chắn của một phân phối, paper sử dụng thêm Router Entropy Loss:

$$L_{\text{entropy}} = \sum_{i=1}^N P_i \log(P_i) \quad (21)$$

Phân phối càng đều, entropy cao, Top-P kích hoạt nhiều expert hơn

Phân phối càng sắc, entropy thấp, Top-P kích hoạt ít expert hơn

Hàm loss cuối cùng có thể được mô tả tổng quát như sau:

$$L_{\text{total}} = L_{\text{LM}} + \lambda_1 L_{\text{P-Penalty}} + \lambda_2 L_{\text{entropy}} \quad (22)$$

Trong đó:

- L_{LM} là language modeling loss.
- $L_{\text{P-Penalty}}$ giúp điều chỉnh việc dùng expert lớn.

- L_{entropy} giúp kiểm soát số expert được kích hoạt.
- λ_1, λ_2 là hệ số điều chỉnh.

5. Thiết kế kích thước expert

Vậy thì làm sao phân bố kích thước expert cho hợp lý

5.1. Geometric Strategy

Geometric strategy dùng cấp số nhân, ví dụ:

$$\{1, 2, 4, 8, 16, 32, 64, 128\} \quad (23)$$

Cách này tạo ra khoảng cách rất lớn giữa expert nhỏ và expert lớn. Hạn chế là expert nhỏ có thể quá yếu, dẫn đến việc không được sử dụng hiệu quả.

5.2. Arithmetic Strategy

Arithmetic strategy dùng cấp số cộng, ví dụ:

$$\{9, 11, 13, 15, 17, 19, 21, 23\} \quad (24)$$

Cách này tạo ra sự khác biệt vừa phải giữa các expert. Paper chủ yếu sử dụng chiến lược này trong thực nghiệm chính vì nó cân bằng hơn.

5.3. Hybrid Strategy

Hybrid strategy kết hợp expert có kích thước giống nhau và khác nhau, ví dụ:

$$\{1, 1, 1, 1, 2, 2, 4, 4\} \quad (25)$$

Cách này cho phép mô hình vừa có một số expert tương tự nhau, vừa có một số expert khác biệt rõ ràng.

6. Thiết lập thực nghiệm

Paper sử dụng tập dữ liệu RedPajama cho pre-training. Đây là tập dữ liệu mở gồm nhiều nguồn như Common Crawl(dữ liệu web), C4(dữ liệu văn bản), GitHub(dữ liệu code), Wikipedia(tri thức bách khoa), books(dữ liệu sách), arXiv(dữ liệu báo) và StackExchange(dữ liệu kỹ thuật chuyên môn).

Các mô hình được so sánh gồm:

- Dense model là mô hình thông thường không có MoE.
- homogeneous MoE là mô hình MoE trong đó các lớp FFN được thay bằng MoE layer có các expert đồng nhất.
- HMoE là mô hình MoE tuy nhiên các lớp FFN được thay bằng MoE layer có các expert không đồng nhất.


Các benchmark đánh giá gồm:

- PIQA(Physical Interaction Question Answering): khả năng suy luận vật lý.
- HellaSwag: khả năng hoàn thành tình huống hợp lý.
- BoolQ : khả năng trả lời câu hỏi đúng ;
- ARC(AI2 Reasoning Challenge): bộ câu hỏi khoa học;
- Winogrande: khả năng hiểu tham chiếu trong ngữ cảnh;
- SIQA(Social Interaction Question Answering): khả năng suy luận xã hội.

Paper đánh giá mô hình trong thiết lập zero-shot. Ngoài ra, để so sánh công bằng, paper dùng FLOPs(chi phí tính toán) thay vì số token huấn luyện, vì số tham số được kích hoạt ở HMoE và Top-P Routing có thể thay đổi động.

Do số tham số kích hoạt của HMoE và Top-P routing thay đổi động trong quá trình huấn luyện, Paper tính số tham số kích hoạt trung bình (Average Activated Parameters) trên 3 triệu token sau khi huấn luyện hoàn tất.

7. Kết quả thực nghiệm



(a) So sánh quan hệ giữa số tham số được kích hoạt khi mô hình xử lý token và loss

(b) Mức tham số được kích hoạt

(c) Tỷ lệ loss theo tham số kích hoạt

Hình 3: Kết quả thực nghiệm của phiên bản HMoE và MoE truyền thống.

Nhận xét:

- Với hình a, cùng chi phí tính toán thì HMoE thường đạt loss thấp hơn tại số tham số kích hoạt nhỏ hơn.
- Với hình b, ở cùng một chi phí thì HMoE có tham số kích hoạt thấp hơn MoE truyền thống.
- Với hình c, khi có đủ chi phí huấn luyện thì HMoE đạt loss thấp hơn MoE truyền thống.

7.1. IsoFLOP Analysis

IsoFLOP Analysis là cách so sánh các mô hình dưới cùng ngân sách tính toán. Điều này quan trọng vì hai mô hình có thể có số tham số khác nhau hoặc số tham số kích hoạt khác nhau.

Kết quả cho thấy khi ngân sách huấn luyện còn thấp, HMoE chưa vượt trội rõ rệt so với MoE truyền thống. Tuy nhiên, khi FLOPs tăng, HMoE dần cho thấy lợi thế ổn định hơn. Đặc biệt, HMoE cần ít tham số kích hoạt hơn nhưng vẫn đạt hiệu năng tốt hơn.

7.2. Kết quả trên benchmark

Method	Activated Parameters	PIQA	hellaswag	BoolQ	ARC-Easy	winogrande	SIQA	AVG
7×10^{19} FLOPs Training								
Dense-0.2B	176M	56.20	26.83	61.43	31.05	51.69	32.65	43.30
MoE-0.4B (Top-K)	163M	57.67	27.81	62.13	29.70	50.59	32.82	43.45
MoE-0.4B (Top-P)	173M	56.92	27.73	56.54	30.18	51.67	32.89	42.66
HMoE-0.4B (Top-K)	153M	56.67	28.26	59.80	31.93	52.49	32.91	43.68
HMoE-0.4B (Top-P)	173M	58.98	28.10	60.78	34.14	52.21	32.83	44.51
2.6×10^{20} FLOPs Training								
Dense-1B	1.32B	58.92	29.57	61.70	35.26	51.85	32.86	45.03
MoE-3B (Top-K)	0.77B	61.92	32.80	60.06	33.96	52.51	32.58	45.64
MoE-3B (Top-P)	1.23B	61.42	32.16	61.47	33.51	52.27	32.91	45.62
HMoE-3B (Top-K)	0.70B	61.04	32.89	60.26	36.14	52.49	32.82	45.94
HMoE-3B (Top-P)	0.68B	61.79	33.22	61.69	36.49	52.96	33.00	46.53
9×10^{20} FLOPs Training								
MoE-16B (Top-P)	3.83B	64.96	41.33	62.56	41.40	51.85	32.91	49.16
HMoE-16B (Top-P)	1.77B	65.12	43.03	61.40	44.21	52.09	33.27	49.85


Hình 4: So sánh hiệu năng giữa Dense, MoE và HMoE trên sáu benchmark

Từ bảng trên cho thấy HMoE vượt MoE đồng nhất trên nhiều benchmark trong cùng mức chi phí huấn luyện, đồng thời cần ít tham số kích hoạt hơn. Điều này chứng minh HMoE cải thiện cả hiệu năng và hiệu quả tính toán.

8. Ablation Study

8.1. Ảnh hưởng của P-Penalty Loss

Paper thực hiện ablation study để kiểm tra vai trò của các auxiliary losses. Kết quả cho thấy HMoE với P-Penalty Loss đạt hiệu quả tốt nhất. Nếu không dùng auxiliary loss, hoặc chỉ dùng load balancing loss truyền thống, mô hình không kiểm soát tốt xu hướng ưu tiên expert lớn.




Hình 5: Ablation study về ảnh hưởng của auxiliary losses. P-Penalty Loss giúp HMoE đạt hiệu quả tốt hơn.

8.2. Ảnh hưởng của mức độ heterogeneity

Paper cũng khảo sát các kiểu phân phối kích thước expert. Kết quả cho thấy geometric strategy thường kém hơn vì khoảng cách giữa expert nhỏ và expert lớn quá lớn. Arithmetic strategy ổn định hơn, trong khi hybrid strategy cũng cho thấy tiềm năng tốt.

Điều này cho thấy việc thiết kế kích thước expert là một yếu tố quan trọng. Không phải cứ làm expert càng khác nhau càng tốt, mức độ khác nhau cần được kiểm soát hợp lý.




Hình 6: So sánh hiệu năng trung bình của các chiến lược thiết kế expert và tỷ lệ kích hoạt expert trong chiến lược Geometric

9. Phân tích chuyên sâu

9.1. Chuyên môn hóa của expert


Một mục tiêu quan trọng của HMoE là giúp expert chuyên môn hóa tốt hơn. Paper phân tích độ giống nhau giữa các expert bằng Wasserstein distance trên phân phối token mà từng expert xử lý.



Hình 7: So sánh phân phối token giữa các expert

Kết quả cho thấy trong homogeneous MoE, các expert có xu hướng gom thành một vài nhóm lớn, cho thấy chúng chưa thật sự chuyên biệt. Trong HMoE, các expert có kích thước gần nhau thường tạo thành các cụm riêng biệt, thể hiện sự chuyên môn hóa rõ hơn.

9.2. Token khó và token dễ



Hình 8: Quan sát những token có độ khó khác nhau và các expert được kích hoạt

Kết quả cho thấy HMoE có khả năng phân bổ token theo độ khó: token dễ thường được xử lý bởi expert nhỏ hơn, còn token khó có xu hướng kích hoạt expert lớn hơn. Điều này phù hợp với mục tiêu thiết kế của HMoE là dùng tài nguyên tính toán linh hoạt theo độ phức tạp của đầu vào.

10. Hiệu quả tính toán

Trong giai đoạn huấn luyện, HMoE có tốc độ tương đối gần với MoE truyền thống khi tổng số tham số và số expert giống nhau. Tuy nhiên, trong suy luận, HMoE có lợi thế vì số tham số kích hoạt trung bình thấp hơn.

Paper cũng đề cập rằng huấn luyện HMoE có một số thách thức về phần cứng do expert có kích thước khác nhau. Các expert không thể luôn được xử lý bằng batched matrix multiplication như trong MoE đồng nhất. Vì vậy, cần các kỹ thuật triển khai hiệu quả hơn như block sparse computation hoặc heterogeneous expert parallelism.

Bảng 1: Ví dụ so sánh hiệu quả giữa HMoE và MoE

Mô hình	Training Samples/s	Average Activated Parameters
HMoE-0.4B	13.83	153M
MoE-0.4B	13.86	163M

Bảng trên cho thấy tốc độ huấn luyện của HMoE và MoE gần như tương đương, nhưng HMoE sử dụng ít tham số kích hoạt hơn.

11. Đánh giá cá nhân

Theo em, điểm mạnh lớn nhất của paper là ý tưởng đơn giản nhưng hợp lý. Trong thực tế, không phải mọi token đều có độ khó như nhau. Vì vậy, việc sử dụng các expert có cùng kích thước cho mọi trường hợp là chưa tối ưu. HMoE giải quyết vấn đề này bằng cách cho phép expert có năng lực khác nhau.

Một điểm mạnh khác là paper không chỉ đề xuất kiến trúc mới mà còn chỉ ra rằng HMoE trực tiếp chưa đủ tốt. Từ đó, paper đề xuất P-Penalty Loss để kiểm soát việc sử dụng expert lớn. Điều này làm cho đóng góp của paper thuyết phục hơn.

Tuy nhiên, paper cũng có một số hạn chế.

- Thứ nhất, việc triển khai HMoE phức tạp hơn MoE truyền thống vì expert có kích thước khác nhau.
- Thứ hai, việc cấu trúc giữa các chuyên gia có kích thước khác nhau khiến HMoE gặp khó khăn rất lớn trong việc phân bổ tài nguyên trên phần cứng.
- Thứ ba, việc sử dụng cấu trúc lai giữa MoE và HMoE đem lại hiệu suất cao hơn tuy nhiên paper đang tập trung vào cấu trúc thiết kế cấp số cộng.
- Thứ tư, việc khởi tạo tham số giống nhau cho tất cả expert mà không quan tâm tới lớn nhỏ.
- Thứ năm, paper mới chủ yếu khảo sát Top-K và Top-P Routing, trong khi còn nhiều chiến lược hiện đại khác có thể kết hợp với
- Thứ sáu, hiệu quả của HMoE ở quy mô cực lớn vẫn cần được nghiên cứu

12. Kết luận

Paper *HMoE: Heterogeneous Mixture of Experts for Language Modeling* đề xuất một hướng tiếp cận mới cho kiến trúc Mixture of Experts. Thay vì sử dụng các expert đồng nhất, paper thiết kế các expert có kích thước khác nhau để phù hợp với token có độ phức tạp khác nhau.

Đóng góp quan trọng nhất của paper gồm:

- đề xuất HMoE với expert có kích thước khác nhau;
- đề xuất P-Penalty Loss để khuyến khích sử dụng expert nhỏ;

- chứng minh HMoE có thể đạt hiệu năng tốt hơn MoE truyền thống;
- cho thấy HMoE có thể giảm số tham số kích hoạt trung bình.

Từ các kết quả thực nghiệm, có thể thấy HMoE là một hướng nghiên cứu tiềm năng trong việc xây dựng các mô hình ngôn ngữ lớn hiệu quả hơn. Trong tương lai, HMoE có thể được kết hợp với các chiến lược routing mới, shared experts, hoặc các kỹ thuật tối ưu suy luận để cải thiện hơn nữa hiệu năng và chi phí tính toán.

Tài liệu tham khảo

Tài liệu

- [1] An Wang, Xingwu Sun, Ruobing Xie, Shuaipeng Li, Jiaqi Zhu, Zhen Yang, Pinxue Zhao, Weidong Han, Zhanhui Kang, Di Wang, Naoaki Okazaki, and Cheng-zhong Xu. *HMoE: Heterogeneous Mixture of Experts for Language Modeling*. Proceedings of EMNLP, 2025.
- [2] Siyuan Mu, Sen Lin. *A Comprehensive Survey of Mixture-of-Experts: Algorithms, Theory, and Applications*. arXiv, 2025.
- [3] Zhicheng Ma, Xiang Liu, Zhaoxiang Liu, Ning Wang, Yi Shen, Kai Wang, Shuming Shi, Shiguo Lian. *Mixture of Heterogeneous Grouped Experts for Language Modeling*. arXiv, 2026.
- [4] William Fedus, Barret Zoph, and Noam Shazeer. *Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity*. Journal of Machine Learning Research, 2022.